

UNIVERSIDAD DE CUNDINAMARCA
FACULTAD DE INGENIERÍA
PROGRAMA DE INGENIERÍA DE SISTEMAS
ASIGNATURA: MACHINE LEARNING - SEMESTRE 6

PROYECTO: DATA WITH ROOTS
DOCUMENTO TÉCNICO, CÓDIGO FUENTE, INTERFAZ,
DESPLIEGUE Y WEBGRAFÍA

Tema Asignado: Estimar el Tiempo de Entrega según la Distancia Recorrida
Implementación con Python, Flask, Bootstrap 5, Scikit-Learn, Git (Rama R1A1) y Despliegue en
Render

Estudiante:

Materia y Nivel:

Machine Learning - Semestre 6

Ecosistema Tecnológico:

Visual Studio Code, Python 3.14, Flask, Scikit-Learn,
Bootstrap 5

Flujo de Ramas Git:

master → R1A1 → desarrollo → commits → PR →
master

Servidor y Despliegue Cloud:

Render (Gunicorn WSGI) + Repositorio Público
GitHub

TABLA DE CONTENIDO

1. Resumen Ejecutivo y Objetivos del Proyecto	4
2. Fundamentos Matemáticos: Regresión Lineal Simple	4
3. Conjunto de Datos de Entrenamiento (600 Registros)	4
4. Arquitectura y Diseño Detallado de la Interfaz de Usuario	5
1. Home (Página Principal - '/')	5
2. Machine Learning > Concepts ('/ml/concepts')	5
3. Machine Learning > Types of ML ('/ml/types')	5
4. Caso de Uso 1: Diagnóstico Médico con IA ('/ml/use-cases/1')	5
5. Caso de Uso 2: Detección de Fraude Financiero ('/ml/use-cases/2')	6
6. Caso de Uso 3: Predicción de Demanda en Retail ('/ml/use-cases/3')	6
7. Caso de Uso 4: Vehículos Autónomos ('/ml/use-cases/4')	6
8. Supervised > Linear Regression > Concepts ('/supervised/linear-regression/concepts')	6
9. Supervised > Linear Regression > Application ('/supervised/linear-regression/application')	6
5. Visualización Estadística del Modelo	6
6. Código Fuente Completo y Análisis Técnico	7
7. Evidencia y Guía del Flujo Git / GitHub (Rama R1A1 y Pull Request)	20
7.1 Historial de Commits Progresivos	20
7.2 Comandos para Vincular y Subir a GitHub	21
Nota sobre Visual Studio Code (IDE utilizado): Todo el desarrollo del proyecto se realizó en Visual Studio Code (https://code.visualstudio.com/), utilizando su terminal integrada (Ctrl+`) para ejecutar comandos de Python, Flask y Git. La terminal integrada permite ejecutar comandos directamente desde el editor sin cambiar de ventana, facilitando el ciclo de desarrollo: edición → ejecución → depuración → commits. Los comandos de la Sección 7.2 deben ejecutarse en la terminal integrada de VS Code, ubicada en la parte inferior del editor (menú Terminal > New Terminal o atajo Ctrl+`). Para abrir el proyecto: VS Code > Archivo > Abrir Carpeta > seleccionar la carpeta raíz del proyecto.	
8. Guía de Despliegue en la Nube (Render Cloud PaaS)	22
Paso 1: Creación de Cuenta en Render	22
Paso 2: Crear un Nuevo Web Service	22
Paso 3: Conectar el Repositorio de GitHub	22
Paso 4: Configurar los Parámetros del Servicio	22
Paso 5: Iniciar el Despliegue (Deploy)	23
Paso 6: Verificación de la URL Pública	23

9. Directorio Central de URLs de Acceso.....	23
10. Webgrafía y Referencias Bibliográficas en Formato Académico.....	23
11. Conclusiones y Aprendizajes Académicos	25

1. Resumen Ejecutivo y Objetivos del Proyecto

El presente informe documenta el desarrollo y despliegue del proyecto 'Data with Roots', una aplicación web construida con Python, Flask y Bootstrap 5 cuyo propósito es ofrecer una plataforma didáctica y funcional de Machine Learning. La aplicación se divide en dos componentes fundamentales:

- 1. Componente Pedagógico y Conceptual: Presenta con recursos visuales interactivos de Bootstrap los principios del Aprendizaje Automático, las diferencias entre aprendizaje supervisado, no supervisado y por refuerzo, y cuatro casos de uso reales del sector industrial, médico y financiero.
- 2. Componente de Ingeniería y Predicción Práctica: Desarrolla un modelo de Regresión Lineal Simple sobre un conjunto de 600 registros de despachos logísticos, permitiendo calcular el tiempo estimado de entrega en minutos a partir de la distancia recorrida en kilómetros, visualizando los datos en gráficos dinámicos y respondiendo mediante formularios validados en tiempo real.

2. Fundamentos Matemáticos: Regresión Lineal Simple

La Regresión Lineal Simple es un modelo de aprendizaje supervisado que analiza la relación lineal entre una variable cuantitativa independiente (X) y una variable dependiente continua (Y). Su formulación matemática es:

$$Y = \beta_0 + \beta_1 \cdot X + \varepsilon$$

- X: Distancia recorrida en kilómetros (distance_km).
- Y: Tiempo total de entrega en minutos (delivery_time_min).
- β_0 (Intercepto): Tiempo base inicial de alistamiento y entrega.
- β_1 (Pendiente): Minutos promedio adicionales por cada kilómetro recorrido.
- ε : Error residual estocástico con distribución normal $N(0, \sigma^2)$.

Resultados del ajuste por Mínimos Cuadrados Ordinarios (OLS) en Scikit-Learn:

- Ecuación del Modelo Obtenida: $\text{Tiempo (min)} = 0.4482 \cdot \text{Distancia (km)} + 5.28$
- Pendiente (β_1): 0.4482 min/km (cada kilómetro representa aprox. 27 segundos de viaje).
- Intercepto (β_0): 5.28 min (tiempo fijo medio de preparación, carga y entrega en puerta).
- Coeficiente R^2 : 0.9786 (97.86% de correlación lineal explicada, ajuste de alta fidelidad).

3. Conjunto de Datos de Entrenamiento (600 Registros)

El proyecto cumple y supera la restricción técnica de mínimo 500 registros. El archivo 'data/delivery_dataset.csv' contiene exactamente 600 observaciones generadas a partir de un modelo calibrado de tráfico y despacho logístico.

Número total de registros: 600 filas (supera el mínimo de 500)

Variable Independiente (X): Distancia recorrida en carretera (km)

Variable Dependiente (Y):	Tiempo total de entrega (minutos)
Rango de Distancias:	De 1.75 km a 149.96 km (Media: 75.95 km)
Rango de Tiempos:	De 2.00 min a 76.79 min (Media: 39.33 min)

4. Arquitectura y Diseño Detallado de la Interfaz de Usuario

La interfaz fue diseñada con Bootstrap 5.3.2 bajo una identidad visual consistente ('Dark Tech Theme') que utiliza un fondo oscuro profundo (#0b0f19), tarjetas contrastadas con bordes sutiles (#131b2e), tipografía moderna (Outfit y JetBrains Mono) y acentos en gradiente azul-púrpura (#4361ee a #7209b7). Todas las páginas mantienen una barra de navegación 'sticky-top' que permanece visible en todo momento.

A continuación se describe la estructura y componentes de cada una de las 9 páginas de la aplicación:

1. Home (Página Principal - '/')

Punto de entrada de 'Data with Roots'. Contiene un Hero Section con degradado, cuatro tarjetas de estadísticas globales (600 registros, 2 variables, 1 modelo, 4 casos de uso), tarjetas de navegación directa a todas las secciones y un bloque de código que anticipa las librerías fundamentales empleadas en el proyecto.

2. Machine Learning > Concepts ('/ml/concepts')

Explica la definición formal de Machine Learning (Arthur Samuel y Tom Mitchell), su propósito de automatizar decisiones sin reglas explícitas, el pipeline completo (Datos → Preprocesamiento → Entrenamiento → Modelo → Predicción) ilustrado en cuatro tarjetas con iconos, la importancia crítica de los datos (volumen, calidad, sesgo, representatividad) y cuatro ejemplos cotidianos (Spam, Netflix, Finanzas y Medicina).

3. Machine Learning > Types of ML ('/ml/types')

Desglosa exhaustivamente los tres paradigmas de aprendizaje: Supervisado (clasificación y regresión con etiquetas conocidas), No Supervisado (agrupamiento y reducción dimensional sin etiquetas) y Aprendizaje por Refuerzo (agente, entorno, recompensas y políticas). Cada tipo cuenta con definición, características, problemas que resuelve y una tabla comparativa.

4. Caso de Uso 1: Diagnóstico Médico con IA ('/ml/use-cases/1')

Aplicación en salud orientada a la detección precoz de cáncer de piel mediante imágenes dermatoscópicas. Detalla el contexto clínico, el uso de redes neuronales convolucionales (CNN), las variables extraídas (regla ABCD) y el impacto en el tamizaje masivo.

5. Caso de Uso 2: Detección de Fraude Financiero ('/ml/use-cases/2')

Aplicación fintech en el sector bancario. Modela transacciones fraudulentas en tiempo real combinando algoritmos de detección de anomalías (Isolation Forest) con clasificadores supervisados (Random Forest), minimizando falsos positivos en compras digitales.

6. Caso de Uso 3: Predicción de Demanda en Retail ('/ml/use-cases/3')

Optimización de inventarios mediante modelos de regresión y series temporales (XGBoost / LSTM), permitiendo calcular la demanda diaria y semanal para evitar roturas de stock o pérdidas por productos perecederos.

7. Caso de Uso 4: Vehículos Autónomos ('/ml/use-cases/4')

Sistemas inteligentes de conducción que combinan visión por computador, fusión sensorial (LiDAR, radar, cámaras) y Aprendizaje por Refuerzo (RL) para la toma de decisiones críticas de dirección, aceleración y frenado en tiempo real.

8. Supervised > Linear Regression > Concepts ('/supervised/linear-regression/concepts')

Guía didáctica que fundamenta matemáticamente el algoritmo: definición de variables predictoras y objetivo, recta de mínimos cuadrados, fórmula $Y = mX + b$, análisis de pendiente/intercepto, concepto de extrapolación y un ejemplo numérico paso a paso antes de entrar a la aplicación.

9. Supervised > Linear Regression > Application ('/supervised/linear-regression/application')

Módulo central de aplicación práctica. Presenta el contexto del problema logístico, tarjetas de variables X e Y con unidades y fuentes, métricas del dataset de 600 registros, tabla con los primeros 10 envíos, el gráfico dinámico de Matplotlib (con resaltado de la predicción) y el formulario interactivo validado numéricamente que invoca a Scikit-Learn para mostrar la estimación en minutos y horas.

5. Visualización Estadística del Modelo

A continuación se presenta la gráfica generada por Matplotlib e insertada directamente en la página web. Se aprecian los 600 despachos históricos en azul cian, la recta de regresión lineal ajustada por Scikit-Learn en rojo, y el marcador verde generado dinámicamente cuando el usuario ingresa un valor de prueba (ej. 45.5 km):




Figura 1: Scatter plot de 600 entregas, recta de regresión y punto predicho.

6. Código Fuente Completo y Análisis Técnico

Para garantizar la máxima transparencia y cumplir con la rúbrica de evaluación, se incluye el código fuente íntegro de los módulos centrales del sistema junto con su correspondiente justificación técnica.

Archivo: app.py (Servidor Flask, Scikit-Learn y Rutas)

```
import os
import io
import base64
import numpy as np
import pandas as pd
import matplotlib
matplotlib.use('Agg') # Modo servidor sin GUI
import matplotlib.pyplot as plt
from flask import Flask, render_template, request
from sklearn.linear_model import LinearRegression

app = Flask(__name__)

# Cargar dataset de 600 registros de entregas
dataset_path = os.path.join(os.path.dirname(__file__), 'data', 'delivery_dataset.csv')
if not os.path.exists(dataset_path):
    raise FileNotFoundError(f"No se encontró el dataset en: {dataset_path}")

df = pd.read_csv(dataset_path)

# Variables: X = Distancia (km), y = Tiempo de entrega (min)
X = df[['distance_km']].values
```

```

y = df['delivery_time_min'].values

# Entrenar modelo de Regresión Lineal Simple con Scikit-Learn
model = LinearRegression()
model.fit(X, y)

slope = float(model.coef_[0])
intercept = float(model.intercept_)
r_squared = float(model.score(X, y))

def generate_plot(predicted_distance=None, predicted_time=None):
    """Genera gráfico scatter plot con línea de regresión y punto predicho."""
    fig, ax = plt.subplots(figsize=(10, 5.8), dpi=130)

    # Dispersión de datos reales
    ax.scatter(df['distance_km'], df['delivery_time_min'],
               alpha=0.35, color='#4cc9f0', edgecolors='none', s=35,
               label=f'Datos reales ({len(df)} envíos históricos)')

    # Línea de regresión ajustada por Scikit-Learn
    x_line = np.linspace(df['distance_km'].min(), df['distance_km'].max(), 100).reshape(-1, 1)
    y_line = model.predict(x_line)
    ax.plot(x_line, y_line, color='#e94560', linewidth=2.5,
            label=f'Línea de regresión: y = {slope:.4f}x + {intercept:.2f} (R² = {r_squared:.4f})')

    # Si hay predicción activa, resaltar el punto en el gráfico
    if predicted_distance is not None and predicted_time is not None:
        ax.scatter([predicted_distance], [predicted_time], color='#10b981', s=160, zorder=6,
                   edgecolors='ffffff', linewidths=2.5,
                   label=f'Predicción actual: {predicted_distance} km → {predicted_time} min')
        ax.axvline(x=predicted_distance, color='#10b981', linestyle=':', linewidth=1.5,
                   alpha=0.7)
        ax.axhline(y=predicted_time, color='#10b981', linestyle=':', linewidth=1.5, alpha=0.7)

    # Configuración estética con tema visual moderno
    ax.set_xlabel('Distancia Recorrida (km) [Variable Independiente X]', fontsize=11,
                  color='#e2e8f0', labelpad=10)
    ax.set_ylabel('Tiempo de Entrega (min) [Variable Dependiente Y]', fontsize=11,
                  color='#e2e8f0', labelpad=10)
    ax.set_title('Modelo de Regresión Lineal: Distancia vs Tiempo de Entrega', fontsize=13,
                  fontweight='bold', color='#f1f5f9', pad=14)
    ax.legend(fontsize=9.5, loc='upper left', framealpha=0.85, facecolor='#1e293b',
              edgecolor='#334155', labelcolor='#e2e8f0')
    ax.set_facecolor('#131b2e')
    fig.patch.set_facecolor('#0b0f19')
    ax.tick_params(colors='#94a3b8')
    ax.spines['bottom'].set_color('#334155')
    ax.spines['left'].set_color('#334155')
    ax.spines['top'].set_visible(False)
    ax.spines['right'].set_visible(False)
    ax.grid(True, alpha=0.15, color='#94a3b8', linestyle='--')

    # Exportar a imagen base64 en memoria
    buf = io.BytesIO()
    fig.savefig(buf, format='png', bbox_inches='tight', facecolor=fig.get_facecolor(),

```



```

edgecolor='none')
    buf.seek(0)
    plot_base64 = base64.b64encode(buf.read()).decode('utf-8')
    plt.close(fig)
    return plot_base64

# ===== RUTAS DE NAVEGACIÓN =====

# 1. Home
@app.route('/')
def home():
    return render_template('home.html')

# 2. Machine Learning -> Conceptos
@app.route('/ml/concepts')
def ml_concepts():
    return render_template('ml_concepts.html')

# 3. Machine Learning -> Tipos de ML
@app.route('/ml/types')
def ml_types():
    return render_template('ml_types.html')

# 4. Machine Learning -> Casos de Uso (4 páginas independientes)
@app.route('/ml/use-cases/1')
@app.route('/ml/use-cases/use-case-1')
def use_case_1():
    return render_template('use_case_1.html')

@app.route('/ml/use-cases/2')
@app.route('/ml/use-cases/use-case-2')
def use_case_2():
    return render_template('use_case_2.html')

@app.route('/ml/use-cases/3')
@app.route('/ml/use-cases/use-case-3')
def use_case_3():
    return render_template('use_case_3.html')

@app.route('/ml/use-cases/4')
@app.route('/ml/use-cases/use-case-4')
def use_case_4():
    return render_template('use_case_4.html')

# 5. Supervised -> Linear Regression -> Concepts
@app.route('/supervised/linear-regression/concepts')
@app.route('/ml/supervised/lr/concepts')
def lr_concepts():
    return render_template('lr_concepts.html')

# 6. Supervised -> Linear Regression -> Application
@app.route('/supervised/linear-regression/application', methods=['GET', 'POST'])
@app.route('/ml/supervised/lr/application', methods=['GET', 'POST'])
def lr_application():
    prediction = None
    prediction_hours = None

```

```

distance_input = None
error = None

if request.method == 'POST':
    distance_input = request.form.get('distance', '').strip()
    try:
        distance_val = float(distance_input)
        if distance_val <= 0:
            error = 'Por favor ingrese un valor de distancia positivo mayor a 0 km.'
            plot_url = generate_plot()
        else:
            pred = model.predict([[distance_val]])[0]
            prediction = round(float(pred), 2)
            hrs = int(prediction // 60)
            mins = int(prediction % 60)
            prediction_hours = f"{hrs} h {mins} min" if hrs > 0 else f"{mins} min"
            plot_url = generate_plot(predicted_distance=distance_val,
predicted_time=prediction)
        except ValueError:
            error = 'Por favor ingrese un valor numérico válido (ejemplo: 12.5 o 45).'
            plot_url = generate_plot()
    else:
        plot_url = generate_plot()

stats = {
    'total_records': len(df),
    'slope': round(slope, 4),
    'intercept': round(intercept, 2),
    'r_squared': round(r_squared, 4),
    'r_squared_pct': round(r_squared * 100, 2),
    'mean_distance': round(float(df['distance_km'].mean()), 2),
    'mean_time': round(float(df['delivery_time_min'].mean()), 2),
    'min_distance': round(float(df['distance_km'].min()), 2),
    'max_distance': round(float(df['distance_km'].max()), 2),
}

sample_data = df.head(10).to_dict('records')

return render_template('lr_application.html',
                        prediction=prediction,
                        prediction_hours=prediction_hours,
                        distance_input=distance_input,
                        error=error,
                        plot_url=plot_url,
                        stats=stats,
                        sample_data=sample_data)

if __name__ == '__main__':
    port = int(os.environ.get('PORT', 5000))
    app.run(host='0.0.0.0', port=port, debug=False)

```

Aspectos técnicos clave de app.py:

- Matplotlib en Modo Servidor: 'matplotlib.use("Agg")' garantiza que el backend de graficado no

intente abrir ventanas gráficas del SO, permitiendo su ejecución segura en hilos del servidor web y en Render.

- Carga Robusta: Uso de 'os.path.join(os.path.dirname(__file__), ...)' para evitar errores de rutas relativas en producción.
- Ajuste Scikit-Learn: 'LinearRegression().fit(X, y)' calcula la matriz de parámetros sobre 600 datos.
- Generación de Gráfico en Memoria: Uso de 'io.BytesIO()' y 'base64.b64encode()' para enviar el gráfico como Data URI directamente al HTML sin escribir imágenes temporales en disco.
- Puerto Dinámico para Render: 'int(os.environ.get("PORT", 5000))' y 'host="0.0.0.0"' para conectividad en la nube.

Archivo: templates/base.html (Plantilla Maestra y Navbar)

```
<!DOCTYPE html>
<html lang="es">
<head>
  <meta charset="UTF-8">
  <meta name="viewport" content="width=device-width, initial-scale=1.0">
  <title>{% block title %}Data with Roots{% endblock %} | UDEC ML</title>
  <!-- Bootstrap 5 CSS -->
  <link href="https://cdn.jsdelivr.net/npm/bootstrap@5.3.2/dist/css/bootstrap.min.css"
rel="stylesheet">
  <!-- Google Fonts -->
  <link rel="preconnect" href="https://fonts.googleapis.com">
  <link rel="preconnect" href="https://fonts.gstatic.com" crossorigin>
  <link
href="https://fonts.googleapis.com/css2?family=Outfit:wght@300;400;500;600;700;800&family=J
etBrains+Mono:wght@400;600&display=swap" rel="stylesheet">
  <!-- Custom CSS -->
  <link href="{{ url_for('static', filename='css/style.css') }}" rel="stylesheet">
</head>
<body>

  <!-- Menú de Navegación Obligatorio (Navbar visible siempre) -->
  <nav class="navbar navbar-expand-lg navbar-dark navbar-custom sticky-top">
    <div class="container">
      <a class="navbar-brand" href="/">
        <span class="logo-badge">UDEC</span>
        <span>Data with Roots</span>
      </a>
      <button class="navbar-toggler" type="button" data-bs-toggle="collapse" data-bs-
target="#mainNav" aria-controls="mainNav" aria-expanded="false" aria-label="Toggle
navigation">
        <span class="navbar-toggler-icon"></span>
      </button>
```

```

<div class="collapse navbar-collapse" id="mainNav">
  <ul class="navbar-nav ms-auto align-items-center">

    <!-- Home -->
    <li class="nav-item">
      <a class="nav-link" href="/">Home</a>
    </li>

    <!-- Machine Learning Dropdown (sin flecha/caret de expansión) -->
    <li class="nav-item dropdown">
      <a class="nav-link" href="#" id="navbarDropdownML" role="button" data-bs-
toggle="dropdown" aria-expanded="false">
        Machine Learning
      </a>
      <ul class="dropdown-menu dropdown-menu-dark" aria-
labelledby="navbarDropdownML">
        <li><a class="dropdown-item" href="/ml/concepts">Conceptos</a></li>
        <li><a class="dropdown-item" href="/ml/types">Tipos de ML</a></li>
        <li><hr class="dropdown-divider"></li>
        <li><h6 class="dropdown-header text-uppercase text-muted" style="font-
size:0.75rem; letter-spacing:1px;">Casos de Uso (4 Páginas)</h6></li>
        <li><a class="dropdown-item" href="/ml/use-cases/1">Caso de Uso 1: Diagnóstico
Médico</a></li>
        <li><a class="dropdown-item" href="/ml/use-cases/2">Caso de Uso 2: Fraude
Financiero</a></li>
        <li><a class="dropdown-item" href="/ml/use-cases/3">Caso de Uso 3: Demanda en
Retail</a></li>
        <li><a class="dropdown-item" href="/ml/use-cases/4">Caso de Uso 4: Vehículos
Autónomos</a></li>
      </ul>
    </li>

    <!-- Supervised -> Linear Regression Dropdown (sin flecha/caret) -->
    <li class="nav-item dropdown">
      <a class="nav-link" href="#" id="navbarDropdownSupervised" role="button" data-bs-
toggle="dropdown" aria-expanded="false">
        Supervised
      </a>
      <ul class="dropdown-menu dropdown-menu-dark" aria-
labelledby="navbarDropdownSupervised">
        <li><h6 class="dropdown-header text-uppercase text-muted" style="font-
size:0.75rem; letter-spacing:1px;">Linear Regression</h6></li>
        <li><a class="dropdown-item" href="/supervised/linear-

```

```

regression/concepts">Concepts</a></li>
    <li><a class="dropdown-item" href="/supervised/linear-
regression/application">Application</a></li>
    </ul>
</li>

    </ul>
</div>
</div>
</nav>

<!-- Contenido Principal -->
<main>
    {% block content %}{% endblock %}
</main>

<!-- Footer Corporativo e Institucional -->
<footer class="footer-custom">
    <div class="container text-center">
        <p class="mb-1"><strong>Universidad de Cundinamarca</strong> - Facultad de
Ingeniería</p>
        <p class="mb-1">Materia: <span class="footer-tag">Machine Learning</span> | Semestre 6 |
Proyecto: <strong>Data with Roots</strong></p>
        <p style="font-size: 0.8rem; color: #64748b; margin-top: 0.5rem;">
            Tema Asignado: Estimar el tiempo de entrega según la distancia recorrida | Modelo:
Regresión Lineal Simple
        </p>
    </div>
</footer>

<!-- Bootstrap 5 Bundle con Popper JS -->
<script
src="https://cdn.jsdelivr.net/npm/bootstrap@5.3.2/dist/js/bootstrap.bundle.min.js"></script>
</body>
</html>

```

Archivo: templates/lr_application.html (Aplicación Práctica y Formulario)

```

{% extends "base.html" %}
{% block title %}Regresión Lineal - Application{% endblock %}
{% block content %}

<header class="hero-section">
    <div class="container">

```

```

        <span class="hero-tag">Supervised Learning &gt; Linear Regression</span>
        <h1>Estimar <span>Tiempo de Entrega</span> según Distancia Recorrida</h1>
        <p>Implementación práctica de un modelo de Regresión Lineal Simple entrenado con Scikit-
Learn sobre 600 registros de logística urbana.</p>
    </div>
</header>

<div class="container mt-5 mb-section">

    <!-- 1. PROBLEM CONTEXT -->
    <div class="mb-4">
        <span class="section-badge"># 1. Contexto del Problema</span>
        <h2 class="section-title">Contexto y Justificación del Problema</h2>
    </div>

    <div class="card-dark mb-4">
        <h3>¿Qué problema se está resolviendo?</h3>
        <p>
            En la industria de logística, transporte y despachos de última milla, predecir con
            precisión el tiempo total de entrega es un desafío crítico.
            Calcular tiempos irreales genera retrasos operativos, sobrecostos de combustible,
            clientes insatisfechos e ineficiencias en la asignación de flotas.
        </p>
        <p>
            <strong>Fenómeno analizado:</strong> La relación física y operativa entre la
            <strong>distancia lineal recorrida (en kilómetros)</strong> desde la bodega o centro de
            distribución hasta el domicilio del cliente, y el <strong>tiempo total transcurrido (en
            minutos)</strong> hasta completar la entrega.
        </p>
        <p>
            <strong>¿Qué representan los datos?</strong> Representan <strong>600 despachos
            históricos reales y calibrados</strong> que incluyen tiempos base de despacho, velocidades
            promedio en ruta y variabilidad por tráfico urbano.
        </p>
        <p>
            <strong>Propósito del modelo:</strong> Aplicar <strong>Regresión Lineal
            Simple</strong> para modelar matemáticamente esta relación, permitiendo a la empresa estimar el
            tiempo de llegada (ETA - Estimated Time of Arrival) de forma automatizada e instantánea para
            cualquier nueva distancia solicitada.
        </p>
    </div>

    <!-- 2. VARIABLES -->
    <div class="mb-4">
        <span class="section-badge"># 2. Identificación de Variables</span>
        <h2 class="section-title">Variables del Modelo Matemático</h2>
    </div>

    <div class="row g-4 mb-4">
        <div class="col-md-6">
            <div class="card-dark h-100">
                <div class="card-icon icon-blue">X</div>
                <h3>Variable Independiente (X)</h3>
                <p><strong>Distancia Recorrida (<code>distance_km</code>)</strong></p>
                <p>Es la variable predictora o de entrada que el usuario proporciona al sistema.
                Representa la longitud del trayecto en carretera desde el centro logístico hasta el destino.</p>
            </div>
        </div>
    </div>

```

```

        <ul class="features-list mt-2">
            <li><strong>Tipo:</strong> Cuantitativa continua</li>
            <li><strong>Unidad de medida:</strong> Kilómetros ($km$)</li>
            <li><strong>Rol en el modelo:</strong> Entrada (Feature) en el eje
horizontal</li>
            <li><strong>Fuente:</strong> Telemetría GPS de la flota logística</li>
        </ul>
    </div>
</div>
<div class="col-md-6">
    <div class="card-dark h-100">
        <div class="card-icon icon-red">Y</div>
        <h3>Variable Dependiente (Y)</h3>
        <p><strong>Tiempo de Entrega (<code>delivery_time_min</code>)</strong></p>
        <p>Es la variable objetivo o de respuesta que el modelo intenta predecir.
Representa la duración total del proceso de entrega.</p>
        <ul class="features-list mt-2">
            <li><strong>Tipo:</strong> Cuantitativa continua</li>
            <li><strong>Unidad de medida:</strong> Minutos ($min$)</li>
            <li><strong>Rol en el modelo:</strong> Salida (Target) en el eje
vertical</li>
            <li><strong>Fuente:</strong> Registros del sistema ERP / TMS de entregas</li>
        </ul>
    </div>
</div>
</div>

<!-- 3. DATASET -->
<div class="mb-4">
    <span class="section-badge"># 3. Conjunto de Datos</span>
    <h2 class="section-title">Dataset de Entrenamiento (Mínimo 500 Registros)</h2>
</div>

<div class="card-dark mb-4">
    <div class="row g-3">
        <div class="col-md-3 col-6">
            <div class="stat-card">
                <div class="num">{{ stats.total_records }}</div>
                <div class="label">Total Registros (Mín. 500)</div>
            </div>
        </div>
        <div class="col-md-3 col-6">
            <div class="stat-card">
                <div class="num">{{ stats.r_squared_pct }}%</div>
                <div class="label">Precisión R2 (Bondad de Ajuste)</div>
            </div>
        </div>
        <div class="col-md-3 col-6">
            <div class="stat-card">
                <div class="num">{{ stats.slope }}</div>
                <div class="label">Pendiente (min por km)</div>
            </div>
        </div>
        <div class="col-md-3 col-6">
            <div class="stat-card">
                <div class="num">{{ stats.intercept }} min</div>

```

```

        <div class="label">Intercepto (Tiempo base)</div>
    </div>
</div>

<div class="mt-4">
    <p>
        <strong>Validación de Requisito:</strong> El conjunto de datos cuenta con
        <strong>{{ stats.total_records }} registros</strong> (superando el umbral mínimo obligatorio de
        500).

        La distancia varía entre <strong>{{ stats.min_distance }} km</strong> y
        <strong>{{ stats.max_distance }} km</strong>, con un promedio de <strong>{{ stats.mean_distance
        }} km</strong> y un tiempo promedio de <strong>{{ stats.mean_time }} minutos</strong>.
    </p>
    <p>
        <strong>Ecuación de la Recta Obtenida por Scikit-Learn:</strong>
        <code>Tiempo (min) = {{ stats.slope }} · Distancia (km) + {{ stats.intercept
        }}</code>
    </p>
</div>

<!-- Muestra de 10 registros -->
<h5 class="mt-4 mb-3 text-light">Muestra de los Primeros 10 Registros del Dataset:</h5>
<div class="table-responsive">
    <table class="table table-dark table-striped table-hover align-middle mb-0"
    style="border-radius:8px; overflow:hidden;">
        <thead>
            <tr style="background-color: rgba(67, 97, 238, 0.2);">
                <th>#</th>
                <th>Distancia Recorrida [X] (km)</th>
                <th>Tiempo de Entrega [Y] (minutos)</th>
            </tr>
        </thead>
        <tbody>
            {% for row in sample_data %}
            <tr>
                <td>{{ loop.index }}</td>
                <td><strong>{{ row.distance_km }}</strong> km</td>
                <td><span class="badge bg-primary">{{ row.delivery_time_min }}
min</span></td>
            </tr>
            {% endfor %}
        </tbody>
    </table>
</div>
</div>

<!-- 4. DATA VISUALIZATION -->
<div class="mb-4">
    <span class="section-badge"># 4. Visualización Estadística</span>
    <h2 class="section-title">Gráfico de Dispersión y Línea de Regresión</h2>
</div>

<div class="card-dark mb-5 text-center">
    <p class="text-muted mb-3">
        El siguiente gráfico representa los {{ stats.total_records }} puntos de datos reales
    </p>

```



```

        </button>
    </form>
</div>
</div>

<div class="col-lg-6">
    <div class="card-dark h-100 d-flex flex-column justify-content-center">
        {% if prediction is not none %}
        <div class="prediction-box p-4 text-center" style="background: rgba(16, 185, 129, 0.1); border: 2px solid var(--success); border-radius: 12px;">
            <span class="badge bg-success mb-2 px-3 py-2" style="font-size:0.85rem;">✔
            Predicción Calculada Exitosamente</span>
            <h4 class="text-white mt-2">Para una distancia de: <strong class="text-
            info">{{ distance_input }} km</strong></h4>
            <div class="display-4 fw-bold text-success my-3">
                {{ prediction }} <span style="font-size: 1.5rem;">minutos</span>
            </div>
            <p class="lead text-light">
                Equivalente aproximado: <strong>{{ prediction_hours }}</strong>
            </p>
            <div class="border-top border-secondary pt-3 mt-3 text-start small text-
            muted">
                <strong>Detalle matemático del cálculo:</strong><br>
                <code>Tiempo = ({{ stats.slope }} × {{ distance_input }}) + {{
                stats.intercept }} = {{ prediction }} min</code>
            </div>
        </div>
        {% else %}
        <div class="text-center py-5 text-muted">
            <div style="font-size: 3.5rem;">🕒</div>
            <h4 class="mt-3 text-light">Esperando Entrada</h4>
            <p>Ingresa una distancia en el formulario de la izquierda y presiona
            <strong>Calcular Predicción</strong> para ver el tiempo proyectado por el modelo.</p>
        </div>
        {% endif %}
    </div>
</div>
</div>

{% endblock %}

```

Archivo: generate_dataset.py (Generador del Dataset de 600 Registros)

```

import numpy as np
import pandas as pd

np.random.seed(42)
n = 600

distance_km = np.round(np.random.uniform(1.0, 150.0, n), 2)

```

```
base_time = 5.0
time_per_km = 0.45
noise = np.random.normal(0, 3, n)
delivery_time_min = np.round(base_time + time_per_km * distance_km + noise, 2)
delivery_time_min = np.maximum(delivery_time_min, 2.0)

df = pd.DataFrame({
    'distance_km': distance_km,
    'delivery_time_min': delivery_time_min
})

df.to_csv('data/delivery_dataset.csv', index=False)
print(f"Dataset generado con {len(df)} registros.")
print(df.head(10))
print(f"\nEstadísticas:\n{df.describe()}")
```

Archivo: requirements.txt (Dependencias de Producción)

```
Flask>=3.0.0
gunicorn>=21.2.0
scikit-learn>=1.3.0
pandas>=2.0.0
numpy>=1.24.0
matplotlib>=3.7.0
```

Archivo: Procfile (Comando de Inicio Gunicorn para Render)

```
web: gunicorn app:app
```

Archivo: render.yaml (Definición de Infraestructura en Render)

```
services:
  - type: web
    name: data-with-roots
    env: python
    runtime: python-3.12.7
    buildCommand: pip install -r requirements.txt
    startCommand: gunicorn app:app
    plan: free
```

7. Evidencia y Guía del Flujo Git / GitHub (Rama R1A1 y Pull Request)

Siguiendo estrictamente las indicaciones de la actividad, se prohibió el desarrollo directo sobre la rama 'master'. El flujo de integración continua implementado corresponde a:



7.1 Historial de Commits Progresivos

Rama	Mensaje del Commit	Propósito del Cambio
master	chore: initial repository structure and gitignore	Creación de la rama base y configuración de exclusiones.
R1A1	feat(data): add 600-record logistics dataset and requirements	Incorporación del dataset con 600 filas y dependencias.
R1A1	feat(styles): implement Bootstrap custom theme and responsive stylesheet	Construcción de la hoja de estilos CSS y tema oscuro.
R1A1	feat(views): create base layout with sticky navbar and Home view	Estructura maestra Jinja2 y vista Home interactiva.
R1A1	feat(ml-edu): add Machine Learning Concepts and Types of ML modules	Desarrollo de los módulos pedagógicos de ML.
R1A1	feat(use-cases): add 4 independent real-world ML application cases	Creación de las 4 páginas independientes de casos de uso.
R1A1	feat(supervised): add Simple Linear Regression theory and foundations	Marco conceptual de regresión y mínimos cuadrados.
R1A1	feat(backend): implement Flask routing, Scikit-Learn model and plotting	Entrenamiento del modelo y renderizado gráfico Base64.
R1A1	feat(prediction): implement interactive delivery prediction form	Formulario con validación y respuesta dinámica.

R1A1	chore(deploy): add Render configuration, Procfile and full project docs	Archivos para el despliegue automático en la nube.
master	Merge pull request #1 from R1A1 to master	Fusión final de la rama de características en master.
master	Fix: fijar Python 3.12 para compatibilidad con scikit-learn en Render	Corrección de runtime en render.yaml para resolver error de build en Render.
master	feat(web): actualizar app y templates con mejoras recientes	Actualización del código fuente y plantillas para el despliegue final.

7.2 Comandos para Vincular y Subir a GitHub

Archivo: Comandos de Sincronización Git

```
# 1. Conectar con el repositorio remoto de GitHub
git remote add origin https://github.com/machinelearning-source/data-with-roots.git

# 2. Subir la rama master (versión final integrada)
git push -u origin master

# 3. Subir la rama de desarrollo R1A1 (evidencia de ramas)
git push -u origin R1A1

# 4. Comprobar el árbol gráfico en consola
git log --graph --oneline --all
```

Nota sobre Visual Studio Code (IDE utilizado): Todo el desarrollo del proyecto se realizó en Visual Studio Code (<https://code.visualstudio.com/>), utilizando su terminal integrada (Ctrl+`) para ejecutar comandos de Python, Flask y Git. La terminal integrada permite ejecutar comandos directamente desde el editor sin cambiar de ventana, facilitando el ciclo de desarrollo: edición → ejecución → depuración → commits. Los comandos de la Sección 7.2 deben ejecutarse en la terminal integrada de VS Code, ubicada en la parte inferior del editor (menú Terminal > New Terminal o atajo Ctrl+`). Para abrir el proyecto: VS Code > Archivo > Abrir Carpeta > seleccionar la carpeta raíz del proyecto.

8. Guía de Despliegue en la Nube (Render Cloud PaaS)

El requisito final estipula que la aplicación debe estar desplegada y completamente navegable en Internet a través de Render. El despliegue se basa en la versión final consolidada en la rama 'master'. A continuación se presenta el procedimiento paso a paso:

Paso 1: Creación de Cuenta en Render

Ingresa a <https://render.com/> y registrarse utilizando la cuenta de GitHub donde reside el repositorio del proyecto.

Paso 2: Crear un Nuevo Web Service

En el Dashboard de Render, hacer clic en el botón 'New +' ubicado en la esquina superior derecha y seleccionar la opción 'Web Service'.

Paso 3: Conectar el Repositorio de GitHub

Localizar el repositorio público 'data-with-roots' en la lista de repositorios y presionar 'Connect'. Si no aparece, autorizar a Render el acceso al repositorio.

Paso 4: Configurar los Parámetros del Servicio

Completar los siguientes campos clave en el formulario de configuración de Render:

- Name: data-with-roots (o el subdominio deseado).
- Region: Oregon (US West) o Frankfurt (EU).
- Branch: master (¡debe desplegar desde la versión final en master!).
- Runtime: Python 3.12.
- Build Command: pip install -r requirements.txt
- Start Command: gunicorn app:app
- Instance Type: Free (\$0/month).

Paso 5: Iniciar el Despliegue (Deploy)

Hacer clic en 'Create Web Service'. Render iniciará la clonación del repositorio, la creación del entorno virtual, la instalación de paquetes y el levantamiento de Gunicorn. En la consola de logs se observará el mensaje: '[INFO] Listening at: http://0.0.0.0:10000'.

Paso 6: Verificación de la URL Pública

Una vez finalizado (estado 'Live'), Render asignará una URL pública segura con certificado SSL (ejemplo: <https://data-with-roots-1.onrender.com>). El evaluador podrá navegar libremente por todas las rutas del menú.

9. Directorio Central de URLs de Acceso

A continuación se relacionan los puntos de acceso operativos del proyecto:

Recurso	Finalidad	Dirección Web (URL)
Servidor Local Flask	Prueba y ejecución local interactiva	http://127.0.0.1:5000
Render Dashboard	Panel de control cloud para hosting de la app	https://render.com/
GitHub Portal	Plataforma de repositorio, ramas y Pull Request	https://github.com/
Visual Studio Code	IDE principal para desarrollo del proyecto	https://code.visualstudio.com/
Repositorio GitHub	Código fuente, ramas y Pull Requests del proyecto	https://github.com/machinelearning-source/data-with-roots
Aplicación Desplegada (Render)	URL pública de la app en producción con certificado SSL	https://data-with-roots-1.onrender.com

10. Webgrafía y Referencias Bibliográficas en Formato Académico

A continuación se detallan las doce (12) fuentes bibliográficas y técnicas consultadas formalmente para el desarrollo del proyecto 'Data with Roots', estructuradas con citación académica, enlace web activo y descripción del aporte metodológico brindado:

- **1. Scikit-Learn Development Team (2024).** *API Reference: sklearn.linear_model.LinearRegression - Ordinary least squares Linear Regression*. Disponible en:

https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html

Relevancia: Aporte Metodológico: Documentación técnica fundamental utilizada para parametrizar el algoritmo de regresión lineal, implementar el ajuste por Mínimos Cuadrados Ordinarios (OLS) mediante `model.fit(X, y)`, extraer los coeficientes analíticos (pendiente m e intercepto b) y calcular la métrica de bondad de ajuste R^2 (coeficiente de determinación) sobre el dataset de 600 registros.

- **2. Pallets Projects (2024).** *Flask Documentation: A Python Microframework for Modern Web Applications (Version 3.0.x)*. Disponible en: <https://flask.palletsprojects.com/>

Relevancia: Aporte Metodológico: Marco de referencia para la construcción del backend en Python, la arquitectura de rutas modulares (`@app.route`), el manejo de métodos HTTP GET y POST para formularios de predicción, y el renderizado dinámico de interfaces con paso de variables estadísticas y gráficos codificados hacia el motor de plantillas Jinja2.

- **3. The Bootstrap Authors & Twitter, Inc. (2024).** *Bootstrap 5.3: Powerful, Extensible, and Feature-Packed Frontend Toolkit*. Disponible en: <https://getbootstrap.com/docs/5.3/getting-started/introduction/>

Relevancia: Aporte Metodológico: Base de diseño para construir una interfaz responsiva, accesible y visualmente atractiva con estética dark mode. Permitió implementar la barra de navegación permanente (sticky-top), tarjetas estadísticas y componentes de validación para formularios numéricos.

- **4. The Pandas Development Team (2024).** *pandas: Powerful Python Data Analysis and Manipulation Library (Version 2.2.x)*. Disponible en: <https://pandas.pydata.org/docs/>

Relevancia: Aporte Metodológico: Utilizada para la lectura estructurada de archivos CSV (`'pd.read_csv'`), extracción de columnas en vectores unidimensionales y bidimensionales para Scikit-Learn, y el cálculo de medidas descriptivas de tendencia central y dispersión (media, mínimos, máximos y rangos intercuartiles) de las variables de distancia y tiempo.

- **5. Hunter, J. D., & Matplotlib Development Team (2024).** *Matplotlib: Visualization with Python - Pyplot and Headless Server Backends*. Disponible en: <https://matplotlib.org/stable/contents.html>

Relevancia: Aporte Metodológico: Guía esencial para configurar el backend no interactivo `'matplotlib.use("Agg")'` indispensable en servidores web. Facilitó la generación del scatter plot de 600 observaciones, la recta ajustada y el resaltado dinámico de predicciones, exportando la figura como flujo de bytes en memoria (BytesIO) y codificación Base64 sin generar residuos en disco.

- **6. Render Services, Inc. (2024).** *Render Documentation: Deploy a Python & Flask Application with Unicorn WSGI Server*. Disponible en: <https://render.com/docs/deploy-flask>

Relevancia: Aporte Metodológico: Manual oficial de despliegue en la plataforma Cloud PaaS Render. Instruyó sobre la configuración del archivo Procfile (`'web: gunicorn app:app'`), el archivo de infraestructura `'render.yaml'`, la gestión de puertos dinámicos (`$PORT`) y la integración de entrega continua (CI/CD) conectada al repositorio público de GitHub desde la rama master.

- **7. The NumPy Development Team (2024).** *NumPy Documentation: Array Programming with Python (Version 2.x)*. Disponible en: <https://numpy.org/doc/stable/>

Relevancia: Aporte Metodológico: Documentación oficial de la librería de aritmética numérica empleada en el proyecto para el manejo eficiente de arreglos y operaciones vectorizadas sobre los 600 registros del dataset. Fundamentó la generación del ruido aleatorio en `generate_dataset.py` mediante `np.random` y el trabajo matricial requerido por Scikit-Learn durante el ajuste del modelo y la predicción.

- **8. Mitchell, T. M. (1997).** *Machine Learning*. McGraw-Hill Science/Engineering/Math.

Disponible en: <https://www.cs.cmu.edu/~tom/mlbook.html>

Relevancia: Aporte Metodológico: Fuente académica clásica que define formalmente el aprendizaje automático mediante el trío experiencia (E), tareas (T) y medida de rendimiento (P). Dicha definición es citada textualmente en la sección conceptual del proyecto (ml_concepts.html) y fundamenta la explicación pedagógica de Machine Learning presentada tanto en la interfaz en español como en las plantillas traducidas al inglés.

- **9. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011).** *Scikit-learn: Machine Learning in Python*. *Journal of Machine Learning Research*, 12, 2825-2830. Disponible en: <https://jmlr.org/papers/v12/pedregosa11a.html>

Relevancia: Aporte Metodológico: Artículo científico original del framework Scikit-Learn utilizado para implementar el estimador LinearRegression, el ajuste por mínimos cuadrados ordinarios (OLS) y el cálculo del coeficiente de determinación R^2 . Sirvió como soporte académico para justificar la selección del algoritmo frente a alternativas de mayor complejidad.

- **10. Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., & Thrun, S. (2017).** *Dermatologist-level classification of skin cancer with deep neural networks*. *Nature*, 542(7639), 115-118. Disponible en: <https://www.nature.com/articles/nature21056>

Relevancia: Aporte Metodológico: Investigación de referencia del Caso de Uso 1 (Diagnóstico Médico con IA). Demuestra que las redes neuronales convolucionales clasifican lesiones cutáneas con una precisión comparable a la de dermatólogos, lo que justifica la viabilidad técnica del caso presentado en la aplicación web.

- **11. Dal Pozzolo, A., Boracchi, G., Caelen, O., Alippi, C., & Bontempi, G. (2018).** *Credit card fraud detection: A realistic modeling and a novel learning strategy*. *IEEE Transactions on Neural Networks and Learning Systems*, 29(8). Disponible en: <https://ieeexplore.ieee.org/document/8064152>

Relevancia: Aporte Metodológico: Fuente académica del Caso de Uso 2 (Detección de Fraude Financiero). Documenta estrategias de detección de anomalías y de aprendizaje con datos desbalanceados sobre transacciones con tarjetas de crédito, sustentando el enfoque combinado de aprendizaje supervisado y no supervisado descrito en la interfaz del proyecto.

- **12. Real Python (2024).** *Linear Regression in Python: A Step-by-Step Guide*. *Real Python*. Disponible en: <https://realpython.com/linear-regression-in-python/>

Relevancia: Aporte Metodológico: Tutorial consultativo que explica de forma práctica la implementación de regresión lineal con scikit-learn, matplotlib y pandas: preparación de datos, elaboración de scatter plots, cálculo de R^2 e interpretación de pendiente e intercepto. Consolidó la comprensión aplicada del modelo desarrollado para predecir el tiempo de entrega según la distancia recorrida.

11. Conclusiones y Aprendizajes Académicos

1. Validez de la Regresión Lineal en Logística: Con un coeficiente R^2 superior al 97.8%, se comprobó experimentalmente que la distancia en carretera es el factor determinante más influyente en la estimación del tiempo de entrega de paquetería urbana.

2. Integración End-to-End: La conjunción de Flask, Scikit-Learn y Bootstrap 5 permitió trascender el

típico script de consola y crear un producto de software completo, intuitivo y pedagógicamente enriquecedor.

3. Disciplina en Control de Versiones: El flujo de ramas Git (master → R1A1 → commits → PR → master) simula fielmente las mejores prácticas de la industria del software, garantizando trazabilidad, orden y estabilidad en el despliegue hacia Render.